


Agente de Flip-7 com Q-Learning

MATA64 - INTELIGÊNCIA ARTIFICIAL

Um agente aprende quando puxar carta ou parar em uma rodada de Flip-7 contra um adversário determinístico forte.



Decidir sob risco crescente

A cada rodada, o agente enfrenta uma escolha simples:

MATA64 - INTELIGÊNCIA ARTIFICIAL

- **Puxar carta:** aumenta pontos, mas pode repetir uma carta e zerar a rodada.
- **Parar:** preserva a pontuação atual, mas pode deixar o adversário crescer.
- **Buscar Flip-7:** sete cartas diferentes rendem bônus, mas exigem mais risco.

🚩 Pergunta do projeto

- Uma política treinada por Q-Learning consegue equilibrar recuperação, preservação de vantagem e risco de estouro melhor que estratégias manuais?
- Ela também consegue competir contra um agente determinístico de melhor jogada?



Ambiente simplificado de Flip-7

Baralho

MAT64 - INTELIGÊNCIA ARTIFICIAL
Cartas de 0 a 12. A carta 0 aparece uma vez; as demais aparecem em quantidade igual ao próprio valor.

Estouro

Se o jogador compra uma numeração repetida, perde a rodada e sua pontuação final vira 0.

Flip-7

Ao chegar a sete cartas sem repetir, o jogador encerra a rodada com 15 pontos extras.



Adversário e consequência

Adversário especial

MAT64 - INTELIGÊNCIA ARTIFICIAL

O oponente continua comprando. Quando puxa uma carta que o faria estourar, devolve a carta ao monte e abandona a rodada sem perder seus pontos.

Consequência

A tarefa fica difícil: o agente pode estourar, mas o adversário usado no treino e na avaliação tem uma vantagem determinística.



MDP

ESTADO

O estado resume a situação da rodada em categorias discretas.



Diferença de pontuação

MATA64 - INTELIGÊNCIA ARTIFICIAL
Situação do agente no placar.

DESTRUÍDO	↓	$\Delta \leq -20$
PERDENDO	↓	$\Delta < 0$
EMPATADO	↓	$\Delta = 0$
GANHANDO	↓	$0 < \Delta < 20$
AMASSANDO		$\Delta \geq 20$



Cartas do agente

Progresso da mão atual.

INÍCIO	↓	cartas ≤ 2
MEIO	↓	3-4 cartas
PERTO DE FLIP-7		cartas ≥ 5



Risco de repetição

Chance de puxar carta repetida.

BAIXO	↓	risco $< 10\%$
MÉDIO	↓	risco $< 25\%$
ALTO	↓	risco $< 40\%$
CRÍTICO		risco $\geq 40\%$



Cartas do adversário

Progresso do oponente.

INÍCIO	↓	cartas ≤ 2
MEIO	↓	3-4 cartas
PERTO DE FLIP-7		cartas ≥ 5



MDP

AÇÕES

▶ 0 - Puxar carta

- Aumenta a pontuação se a carta for nova.
- Pode aproximar o jogador do bônus de Flip-7.
- Se a numeração repetir, o jogador estoura e termina com 0 pontos.

■ 1 - Parar

- Preserva a pontuação acumulada na rodada.
- Evita o risco imediato de estouro.
- Permite que o adversário continue até encerrar sua própria jogada.

MDP

TRANSIÇÕES

✓ Carta segura

A carta entra na mão, soma pontos e a rodada continua.

MATA64 - INTELIGÊNCIA ARTIFICIAL

⚠ Estouro

Uma carta repetida zera a pontuação do jogador e encerra sua participação.

■ Parada voluntária

O jogador para e mantém a pontuação acumulada.

🏆 Flip-7

Sete cartas sem repetição dão bônus e encerram a rodada daquele jogador.

🎲 Adversário para

Quando o adversário puxaria uma carta repetida, ele devolve a carta e para.



MDP

RECOMPENSA POR PASSO

A cada ação, o agente recebe um sinal baseado na mudança do saldo entre agente e adversário.



$$R_{passo} = \Delta_{próximo} - \Delta_{anterior}$$

 $\Delta_{anterior}$

DELTA ANTERIOR

Saldo agente - adversário antes da ação escolhida.

 $\Delta_{próximo}$

PRÓXIMO DELTA

Saldo agente - adversário depois da transição da rodada.

MDP

RECOMPENSA TERMINAL

Ao final da rodada, entra uma recompensa baseada no resultado e na margem final.

MATA64 - INTELIGÊNCIA ARTIFICIAL

1/25

$$R_{final} = K_r + K_b \cdot \tanh\left(\frac{\Delta_{final}}{L}\right)$$

K_r

RECOMPENSA BASE

Peso principal para vitória, derrota ou empate.

+100 / 0 / -100

Δ_{final}

DELTA FINAL

Margem final da rodada.

K_b

BÔNUS

Controla quanto a margem influencia a recompensa.

Constante: 50

L

LIMITE PARA REVANCHE

Define quando uma margem já é considerada grande.

Constante: 50

Políticas baseline

✂ Random

MATAS - INTELIGÊNCIA ARTIFICIAL
Escolhe aleatoriamente entre puxar carta e parar. Serve como linha de base mínima.

🛡 Conservador

Evita risco alto e para cedo quando está ganhando. Reduz estouros, mas pode vencer pouco.

💧 Agressivo

Continua comprando quando está atrás ou quando ainda existe chance de buscar Flip-7.

1/25



As baselines deixam claro se o agente aprendido supera regras simples de comportamento.

Regras das políticas manuais

Conservador

Risco alto ou crítico? MATA64 - INTELIGÊNCIA ARTIFICIAL	
SIM: PARAR	NÃO: AVALIAR PLACAR
Está ganhando ou amassando?	
SIM: PARAR	NÃO: BUSCAR RECUPERAÇÃO
Puxa carta se estiver perto de Flip-7 com risco baixo	
Puxa carta se estiver destruído com risco baixo ou médio	
Puxa carta se estiver perdendo com risco baixo	
Caso contrário: parar	

Agressivo

Risco crítico?	
SIM: PARAR	NÃO: CONTINUAR AVALIANDO
Puxa carta se estiver perto de Flip-7	
Puxa carta se estiver destruído ou perdendo	
Puxa carta se estiver empatado ou ganhando com risco baixo ou médio	
Está amassando com risco alto?	
SIM: PARAR	NÃO: PUXAR CARTA



Q-Learning

MATA64 - INTELIGÊNCIA ARTIFICIAL

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

A política final escolhe a ação com maior valor Q em cada estado.

 α

ALPHA

Taxa de aprendizado.

Valor: 0.10

 γ

GAMMA

Peso das recompensas futuras.

Valor: 0.95

 ϵ_0

EXPLORAÇÃO INICIAL

Chance inicial de escolher ação aleatória.

Valor: 0.35

 ϵ_{min}

EXPLORAÇÃO MÍNIMA

Exploração residual no fim do treino.

Valor: 0.02

 N

EPISÓDIOS

Rodadas usadas para treinar a tabela Q.

Valor: 50.000

 $|A|$

AÇÕES

Comprar carta ou parar.

Valor: 2



Pipeline de avaliação

1



Treinar

MATA64 - INTELIGÊNCIA ARTIFICIAL

50.000 episódios
atualizando a tabela Q.

2



Extrair política

Selecionar a melhor ação
estimada para cada
estado.

3



Simular

Rodar 2.000 partidas por
política comparada.

4



Medir

Pontuação, vitórias,
estouros, Flip-7, saldo e
recompensa.


1/25



🚩 Reprodutibilidade

As sementes de aleatoriedade foram fixadas em 42 para manter resultados comparáveis entre execuções.

Recompensa média



Mesmo negativa, a recompensa média do Q-Learning foi a maior em comparação com as políticas manuais.




Taxa de vitória



O Q-Learning apresentou a maior taxa de vitória entre as políticas, superando as estratégias manuais.




Taxa de estouro



O Q-Learning assume mais risco que o conservador, mas estoura menos que a política agressiva.




Taxa de Flip-7



O Flip-7 foi raro em todas as políticas; o desempenho do Q-Learning vem mais do equilíbrio de risco do que da dependência desse bônus.




Pontuação média final



Mesmo contra um adversário com pontuação média alta, o Q-Learning aumenta a pontuação média do agente e mantém o melhor saldo relativo.


Quantidade média de cartas



O Q-Learning mantém mais cartas que as políticas manuais mais simples, mas ainda equilibra o risco e abre mão de ter mais cartas na média quando comparado à política agressiva.



Distribuição final das partidas



RANDOM

11,4%



CONSERVADOR

7,1%



AGRESSIVO

26,2%




Q-LEARNING

38,4%



Severidade das derrotas



Nas derrotas, um delta menos negativo indica que a política reduziu a distância média para o adversário.

O que a política aprendeu?

▶ Tende a puxar carta quando...

MATA64 - INTELIGÊNCIA ARTIFICIAL

- esta destruído ou perdendo no saldo;
- o risco de repetição ainda é baixo ou médio;
- tem poucas cartas e ainda existe espaço para crescer;
- parar apenas preservaria uma derrota provável.

■ Tende a parar quando...

- já está ganhando ou amassando;
- o risco de repetir sobe para alto ou crítico;
- tem cartas suficientes para que perder tudo seja caro;
- preservar vantagem vale mais que buscar margem.





Resumo Geral

MATA64 - INTELIGÊNCIA ARTIFICIAL					
POLÍTICA	RECOMPENSA	PONTOS AGENTE	SALDO	VITÓRIAS	ESTOURO



Observações

Rodada isolada

ADAPTAÇÃO

O jogo foi modelado com uma rodada única.

MELHORIA / CONSEQUÊNCIA

Uma versão multi-rodada permitiria avaliar recuperação e estratégia de longo prazo.

Estado discretizado

ADAPTAÇÃO

Placar, risco e cartas foram resumidos em categorias.

MELHORIA / CONSEQUÊNCIA

Estados mais detalhados poderiam revelar decisões melhores em cenários específicos.



Adversário especial

ADAPTAÇÃO

O adversário usa uma regra fixa e não perde pontos ao evitar estouro.

MELHORIA / CONSEQUÊNCIA

Testar adversários variados mostraria se a política generaliza melhor.

Recompensa parametrizada

ADAPTAÇÃO

A função combina resultado, margem final e variação do saldo.

MELHORIA / CONSEQUÊNCIA

Outros pesos podem mudar o equilíbrio entre risco, vitória e preservação.

Mais Detalhes

MATA64 - INTELIGÊNCIA ARTIFICIAL

 **Abrir Notebook**



